Alware: An Embedded AI System for Real-Time Driver Monitoring

Real-Time Driver State Monitoring and Alerting System

Antonio Nigro Zamur
Gabriel Pereira de Carvalho
Henrique Eduardo dos Santos de Souza
Matheus Kosicov Perugini

PCS3848 Sistemas Embarcados

Escola Politécnica da USP
São Paulo, 2026

Visão Geral do Projeto

Introdução ao Alware

- O Alware é um sistema de IA embarcada para monitoramento do condutor em tempo real.
- Visa reduzir acidentes causados por fadiga e distração através de TinyML.
- Solução de baixo custo otimizada para hardware com recursos limitados.
- Foco em métricas de baixa latência e alta precisão para segurança.

Tópicos da Apresentação

- 1. Contexto e Motivação
- 2. Monitoramento via Câmera (NIR)
- 3. Métricas Comportamentais: EAR/MAR
- 4. Requisitos e Especificações
- 5. Arquitetura do Sistema (RPi 3B+)

1. Contexto e Motivação

Por que Monitorar o Condutor?

1,19M

Mortes anuais no trânsito mundial

50M

Feridos em acidentes por ano

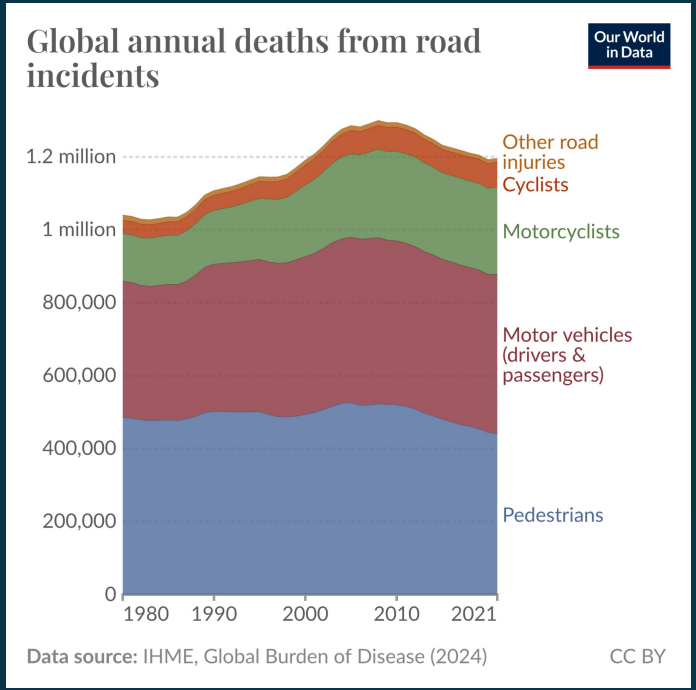

Principais Fatores de Risco:

- Fadiga e sono excessivo
- Distração (uso de celular)
- Consumo de álcool e drogas
- Ausência de cinto de segurança

2. Monitoramento via Câmera (NIR)

Visão de Infravermelho Próximo

- Superação de desafios de iluminação variável, como direção noturna ou túneis.
- Operação no espectro de 850-940 nm para capturar detalhes faciais em escuridão total.
- Independência de luz visível (RGB) para manter a precisão do sistema 24/7.
- Integração com sensores de áudio como redundância em casos de baixa qualidade de imagem.

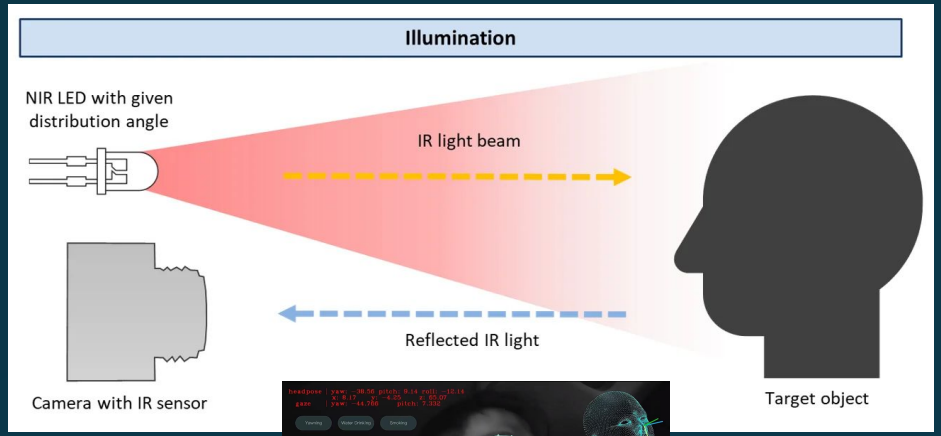

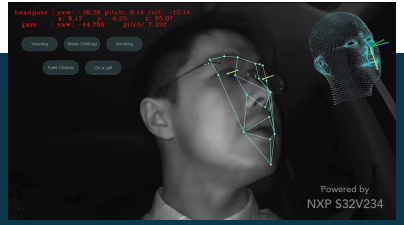

Hardware: Suporte a câmeras com sensibilidade IR e filtros específicos

3. Extração para features para modelo

Métricas Biométricas: EAR e MAR

- Detectam estados de fadiga e distração de forma objetiva através de geometria facial.
- Modelos TinyML leves realizam classificações binárias com alta precisão e baixo processamento.

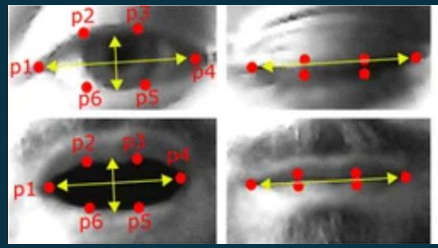

$$\mathrm{EAR} = \mathrm{MAR} = \frac{\|p_2 - p_6\| + \|p_3 - p_5\|}{2\|p_1 - p_4\|}$$

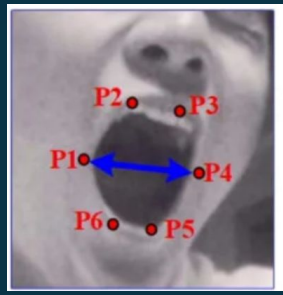

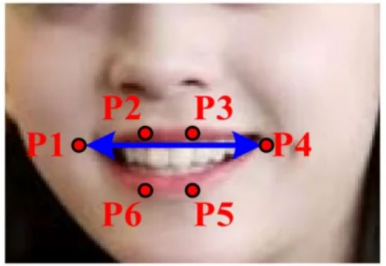

Decisões em Tempo Real:

Latência crítica < 100ms para garantir a segurança do condutor em situações de risco.

4. Trabalho relacionado

State Farm Distracted Driver Dataset

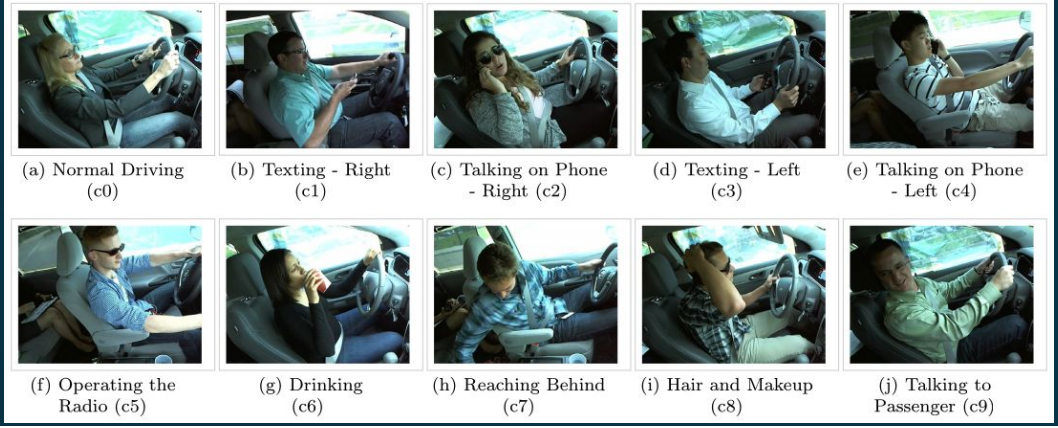

Table 1 Performance comparison of lightweight models in terms of test metrics, computational efficiency, and memory footprint

Model	Accuracy (%)	Loss	Precision (%)	Recall (%)	F1-score (%)	RAM (MB)	Speed (FPS)	Size (MB)
Efficient-Tiny	91.64	0.4243	93.02	92.56	92.01	0.08	26.81	0.43
ESPNetv2-Small	99.50	0.0482	99.45	99.44	99.44	0.22	40.49	0.74
MCUNet	97.85	0.0951	97.69	97.48	97.54	0.03	52.72	0.20
Micro-MobileNet	98.99	0.0300	99.26	99.23	99.24	0.15	37.71	0.60
PhiNets	99.66	0.0175	99.50	99.49	99.49	0.15	36.14	0.60
ShuffleNetLite	86.06	0.6538	92.93	86.23	87.21	1.75	22.27	5.46
SqueezeNetv11	95.81	0.1399	95.85	95.76	95.76	0.05	28.60	0.33

5. Requisitos e Especificações

Critérios de Sucesso do Sistema

REQUISITOS FUNCIONAIS

- Processamento local e offline em tempo real
- Alerta sonoro (>70dB) e visual (500-1000 nits)
- Detecção de sono, celular e distração

REQUISITOS NÃO FUNCIONAIS

- Latência de inferência < 100ms
- Acurácia do modelo superior a 95%
- Disponibilidade cumulativa de 99%

HARDWARE & SEGURANÇA

Câmera ≥ 2MP / 30 FPS com sensibilidade IR. Armazenamento tipo "Caixa Preta" resistente a colisões de até 100 kN e criptografia de ponta.

6. Arquitetura do Sistema (RPi 3B+)

Design e Integração de Componentes

PLATAFORMA COMPUTACIONAL

Raspberry Pi 3B+ com 1GB RAM. Capacidade ideal para execução de modelos TinyML (TensorFlow Lite) e processamento de imagem local.

INTERFACES DE ALERTA

- Alerta Sonoro: Buzzer ativo 5V (~85dB).
- Alerta Visual: LEDs de alta intensidade.
- Conectividade: Módulo de comunicação externa para hub central.

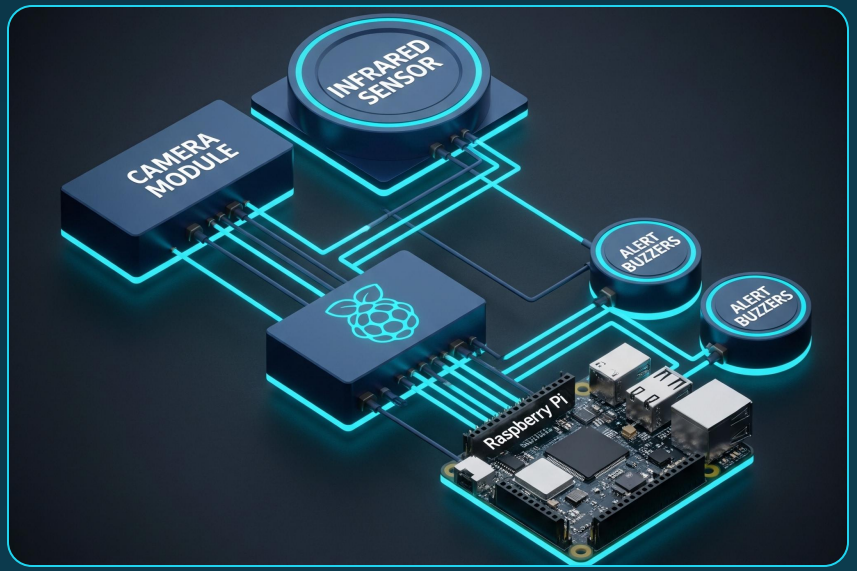

Arquitetura focada em baixa latência e processamento offline

5. Arquitetura do Sistema (RPi 3B+)

Diagrama de arquitetura

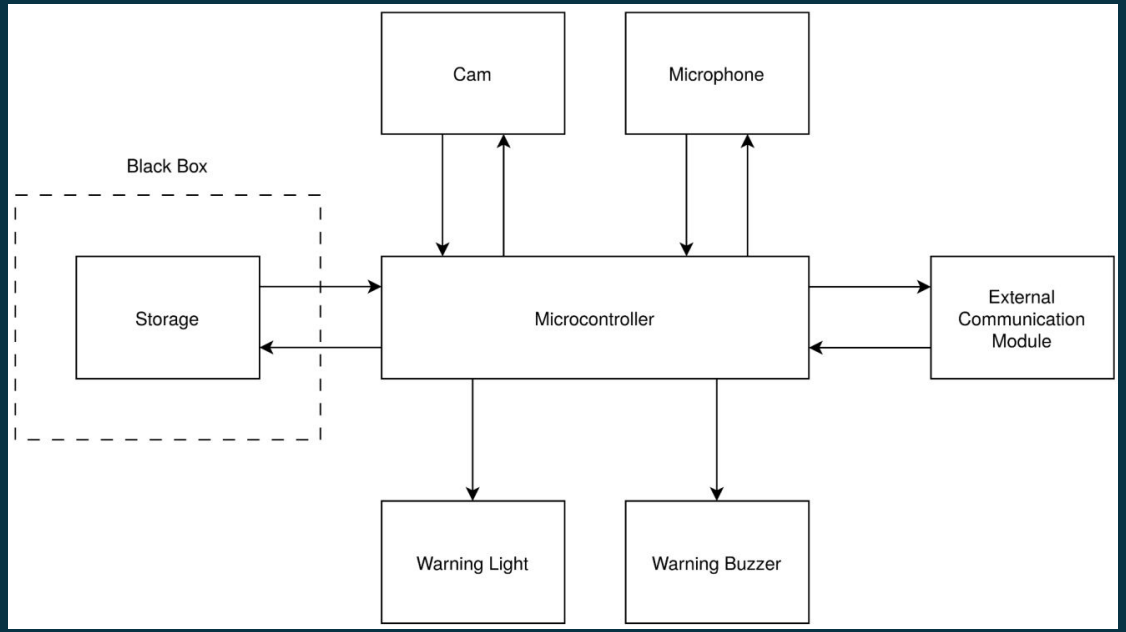

Arquitetura focada em baixa latência e processamento offline